

Задание на Хакатон ML4Pay от Авито

Словарь терминов:

Байер – пользователь, оформляющий покупку товара на Авито.

Селлер – пользователь, размещающий и продающий свой товар на Авито.

Возврат товара – оформление возврата товара байером и его последующая отправка обратно селлеру. Возврат может быть оформлен как на месте сразу после получения товара байером, так и в течение определенного периода после получения товара, при подключенной опции политики возврата по этому товару.

Отмена заказа – отмена заказа со стороны байера или селлера после его оформления, но до выдачи заказа, то есть до возможности оформления возврата.

Контекст

Возвраты товаров создают дополнительную нагрузку на бизнес. Они влияют на логистику, операционные процессы, клиентский опыт и экономику заказов. Чем лучше мы понимаем, какие заказы могут вернуться, тем точнее можем оценивать риски и принимать решения по оптимизации затрат.

Вам будет предоставлен датасет с историческими данными о покупках. Он состоит из нескольких связанных таблиц: с заказами, оплатами, пользователями и дополнительными атрибутами. В этих данных есть информация о товарах, заказах, пользователях и возвратах.

Для большей части периода в данных будет известен признак возврата. Но для первых 10 дней октября 2025 года, с 1 по 10 октября 2025 года, этот признак будет скрыт. При этом все остальные атрибуты заказов за эти даты у вас будут.

Ваша задача: предсказать, какие заказы из этого периода будут возвращены.

Описание задачи

I Этап – техническое решение

Дедлайн выгрузки файла ответа: 10.05.2026 – 23:59

При решении вам необходимо:

- изучить предоставленные таблицы и связи между ними;
- найти признаки, которые могут влиять на возврат;
- построить модель для прогноза;
- сделать предсказание признака ***is_return*** для заказов с 1 по 10 октября 2025 года;
- подготовить итоговый файл в формате: дата - заказ - предсказанный признак возврата / вероятность возврата.

На первом этапе оценка будет технической: мы сравним ваши предсказания с фактическими данными о возвратах за 1-10 октября 2025 года. Команды, чьи прогнозы окажутся наиболее полными и близкими к реальности, пройдут в финал.

При оценке будем смотреть на:

- общую точность (**precision**) и полноту (**recall**) предсказанных вами значений поля **is_return** при сопоставлении с реальными данными по возвратам этих товаров;
- получаемый **F-score** и **ROC-AUC** метрики по вашей модели;
- структуру прогноза: насколько хорошо вы предсказываете возвраты в разных разрезах, например по товарам, заказам, пользователям или другим важным сегментам.

По итогам сопоставления 12.05 будет опубликован рейтинг команд с выводением полученных значений метрик оценки по вашим моделям.

Решения абитуриентов и студентов будут оцениваться отдельно на отборочном и финальном этапе. Далее на финал будут приглашены 5 лучших команд из абитуриентов и 5 лучших команд среди студентов.

Формат файла-ответа:

- Ожидаем файлы с таблицами, предоставляющими сопоставление пар товара (**item_id**) с предсказанным вашей командой бинарным значением флага возврата (поле **is_return**) по заказам созданным за период с 01.10.25 по 10.10.25 (фильтрация по полю **order_create_date**). Пример: item1 - true; item2 - false
- Файл выгружать в формате csv, xlsx, или parquet
- Отправить решение необходимо на почту itmo.hack@itmo.ru с указанием названия команды в теме письма

II Этап – финальная презентация решения

Дедлайн выгрузки презентации: 15.05.2026 – 22:00

В финале от команд уже будет ожидаться не только технический результат, но и подробный рассказ о решении.

Нужно будет подготовить презентацию и объяснить:

- какие факторы сильнее всего влияют на возвраты;
- почему они могут быть важны;
- какие гипотезы вы проверяли;
- какие выводы можно сделать для продукта или бизнеса;
- какие рекомендации можно предложить на основе модели.

Формат презентации:

- Количество слайдов – от 3 до 7;
- Файл выгружать в формате pptx, pdf;
- Отправить презентации необходимо на почту itmo.hack@itmo.ru с указанием названия команды в теме письма, а также в названии файла.

Для работы вам будут предоставлены серверы, на которых можно запускать вычисления, но можно использовать свои ресурсы.

Ниже приложена ссылка на предоставляемые вам датасеты и короткое описание полей: <https://disk.yandex.ru/d/ixLrKRQ88xIBdq> (пароль: 4Vkv_24%~&LS%WgRV;x5+~)

Таблица пользователей

Поле	Описание
<i>user_id</i>	Уникальный идентификатор пользователя в системе (используется как основной ключ для связи с другими таблицами)
<i>iscompany</i>	Булев флаг типа аккаунта: true — компания (юридическое лицо), false — частный пользователь
<i>registrationtime</i>	Дата и время регистрации пользователя на платформе
<i>isblocked</i>	Булев флаг статуса аккаунта: true — пользователь заблокирован, false — активен
<i>firstlistingdate</i>	Дата первого размещения объявления пользователем (характеризует начало активности пользователя как селлера)
<i>gender</i>	Пол пользователя (может отсутствовать или быть неопределённым)

Таблица товаров

Поле	Описание
<i>item_id</i>	Уникальный идентификатор товара (объявления) в системе
<i>title</i>	Заголовок объявления или название товара, указанное пользователем
<i>microcat_name</i>	Название микрокатегории товара (более узкая классификация внутри категории)
<i>category_name</i>	Название основной категории товара (более общий уровень классификации)
<i>user_id</i>	Идентификатор пользователя, разместившего объявление (внешний ключ к таблице пользователей)
<i>starttime</i>	Дата и время публикации объявления на платформе

<i>close_date</i>	Дата и время снятия объявления с публикации; если значение NULL — объявление активно
-------------------	--

Таблица заказов

Поле	Описание
<i>deliveryorder_id</i>	Уникальный идентификатор заказа в системе
<i>order_create_date</i>	Дата создания заказа
<i>order_accept_date</i>	Дата приема заказа байером (финализации заказа)
<i>item_id</i>	Уникальный идентификатор товара (объявления) в системе
<i>buyer_terminal</i>	Терминал (ПВЗ/Почта России), куда байер оформил заказ
<i>seller_terminal</i>	Терминал (ПВЗ/Почта России), куда продавец отнес заказ
<i>delivery_service</i>	Сервис доставки
<i>is_pod</i>	Флаг оплаты при получении (Pay on Delivery)
<i>buyer_id</i>	Внутреннее ID байера
<i>seller_id</i>	Внутреннее ID продавца
<i>order_price</i>	Общая сумма заказа (сумма всех товаров без доставки)
<i>city</i>	Город (по локации байера)
<i>platform_id</i>	Код платформы, на которой байер оформил заказ (ios, android, web, mav) * IOS/Android - мобильные приложения для IOS и Android соответственно; WEB или Desktop - сайт Авито, открываемый с компьютера; MAV (Mobile Avito) - мобильная версия сайта Авито, открываемая с телефона
<i>cancel_date</i>	Дата отмены (только для отменённых заказов)
<i>is_return</i>	Флаг возврата товара (true - произошел возврат, false - возврата не было). Ваше целевое поле, удачи.

Таблица оплат

Поле	Описание
deliveryorder_id	Заказ, по которому платят
created_txtime	Дата оплаты
user_id	Пользователь, оплачивающий заказ
payment_method	Метод оплаты
amount	Сумма оплаты (сумма самого заказа вместе с дополнительными платами - за доставку, комиссия и тд)

FAQ

1. В какой момент можно сделать предсказание? (Если заказ ещё не принят в работу, для него нужно указывать вероятность возврата?)

В предоставленной выгрузке только уже созданные заказы. Поэтому считаем, что по их характеристикам и параметрам связанных сущностей уже можно делать предсказание возврата товара.

2. 1 заказ = 1 товар? Если в заказе несколько разных товаров, то возврат необходимо рассмотреть по каждому отдельному товару и в среднем?

В одном заказе может быть несколько товаров. И так как основной задачей является именно предсказание возврата товара, необходимо рассматривать каждый из товаров внутри заказа отдельно.

3. Исторические данные – это за сколько месяцев/ лет? Можно ли (и нужно ли) тут рассматривать сезонность товаров

В выгрузке мы предоставляем данные из 3 месяцев для обучения модели. На подобранном периоде не должно быть сильного влияния сезонности, однако может наблюдаться небольшой эффект из-за того, что рассматриваются реальные данные.

4. Может ли быть несколько оплат по одному заказу? (часть вещей была по предоплате, часть по постоплате или оплачено в разном формате)

Да, по одному заказу может быть несколько оплат. Например, стоимость доставки заказа может быть включена в общий платеж, а может оплачиваться отдельной транзакцией.

5. Нужно ли подтягивать внешнюю информацию под исторические данные (например, курс валюты, эконом. ситуация в стране или регионе, блокировки интернета и тд)

Задача подразумевает, что модель будет основываться на использовании именно предоставленных вам выгрузок и сочетаний данных из разных таблиц.

6. Будет ли публичный лидерборд?

Да, однако не в процессе работы над моделью. После завершения первого технического этапа и сдачи файлов-решений будет опубликован борд сопоставления команд по метрикам качества предсказания при сравнении с реальными данными.

7. Сколько попыток сдачи есть?

У вас будет 1 попытка сдачи без промежуточной оценки результатов модели. Мы предполагаем, что в процессе работы над моделью вы самостоятельно поделите выборку на обучающую и тестовую и будете проводить предоценку качества модели на этих данных.